

INSTITUT DE MATHÉMATIQUES ET DE SCIENCES PHYSIQUES

(IMSP) – Bénin

MATIÈRE : DATA SCIENCE

PROJET ACADÉMIQUE

Détection de Fraude Bancaire

Benin Bank

Cotonou, Bénin

Dataset : Credit Card Fraud Detection (Kaggle)

Modèles : Logistic Regression · Random Forest · XGBoost · Deep Learning

Équipe du projet

ATIN Caleb
BAPKESSI Aklesso
DAKO Ulrich
HOUNDJO Isaac
SOMALON Marie Gregory

Année universitaire 2025 – 2026

Table des matières

1	Introduction et Problème Métier	2
2	Étape 1 — Compréhension du Problème	2
2.1	Type de problème	2
2.2	Pourquoi la fraude est-elle difficile à détecter?	2
2.3	Métriques et coût des erreurs	2
3	Étape 2 — Nettoyage et Préparation des Données	2
3.1	Présentation du dataset	3
3.2	Valeurs manquantes	3
3.3	Déséquilibre des classes	3
3.4	Gestion des outliers	3
3.5	Stratégie face au déséquilibre	3
3.6	Découpage et standardisation	4
4	Étape 3 — Exploration des Données (EDA)	4
4.1	Distribution des classes	4
4.2	Analyse du montant	4
4.3	Corrélations	4
4.4	Variables influentes	4
5	Étape 4 — Modélisation Machine Learning	4
5.1	Méthodologie	5
5.2	Résultats comparatifs	5
5.3	Analyse des résultats	5
5.4	Surapprentissage (Overfitting)	5
5.5	Modèle recommandé	6
6	Étape 5 — Deep Learning	6
6.1	Architecture du réseau	6
6.2	Résultats	6
6.3	Comparaison avec les modèles ML classiques	6
7	Étape 6 — Explicabilité du Modèle	6
7.1	Importance des variables	7
7.2	Interprétation	7
7.3	Niveau de confiance	7
8	Étape 7 — Sécurité et Éthique	7
8.1	Risques identifiés	7
8.2	Recommandations globales pour la Benin Bank	8
9	Discussion et Limites	8
9.1	Points forts	8
9.2	Limites	8
9.3	Perspectives	8
10	Conclusion et Recommandations	8

1. Introduction et Problème Métier

La Benin Bank, institution financière établie à Cotonou, fait face à une hausse préoccupante des transactions frauduleuses : cartes bancaires volées, fraudes en ligne et activités suspectes de toutes natures. Dans ce contexte critique, la banque souhaite se doter d'un système intelligent capable d'identifier automatiquement les transactions à risque, afin de réduire les pertes financières et d'améliorer la sécurité de ses clients. L'objectif de ce projet est de concevoir, entraîner et évaluer des modèles de machine learning et de deep learning aptes à prédire si une transaction donnée est frauduleuse ou non. La variable cible est binaire :

- Class = 0 : transaction légitime
- Class = 1 : transaction frauduleuse

Le principal défi est la rareté extrême des fraudes dans les données, qui impose une stratégie méthodologique rigoureuse en termes de métriques, d'entraînement, de validation et d'interprétation des résultats.

2. Étape 1 — Compréhension du Problème

2.1 Type de problème

Ce projet relève d'une classification binaire supervisée avec une contrainte métier forte : détecter efficacement la fraude sans bloquer excessivement les clients légitimes. Il s'agit d'un problème déséquilibré (imbalanced classification) car les fraudes sont très rares comparées aux transactions normales.

2.2 Pourquoi la fraude est-elle difficile à détecter ?

- La classe fraude est très minoritaire (moins de 0,2 % des transactions).
- Les comportements frauduleux peuvent ressembler à des comportements normaux en apparence.
- Les variables sont anonymisées via ACP, limitant l'interprétation directe.
- Les erreurs de classification ont des coûts élevés dans les deux sens

2.3 Métriques et coût des erreurs

La métrique la plus critique est le recall de la classe fraude, car un faux négatif correspond à une fraude non interceptée. Cependant, un recall élevé avec une précision trop faible génère trop de faux positifs et dégrade l'expérience client. Le F1-score de la classe fraude est donc retenu comme indicateur principal de compromis.

- Faux négatif : fraude non détectée → perte financière directe, risque réglementaire et réputationnel.
- Faux positif : blocage d'un client innocent → dégradation de l'expérience client, charge opérationnelle de traitement.

3. Étape 2 — Nettoyage et Préparation des Données

3.1 Présentation du dataset

Le dataset utilisé est le Credit Card Fraud Detection disponible sur Kaggle (MLG- ULB). Il contient 284 807 transactions effectuées par des porteurs de cartes européens en septembre 2013. Chaque transaction est décrite par 30 variables numériques (V1 à V28 issues d'une ACP, Time et Amount) et une variable cible Class.

3.2 Valeurs manquantes

L'analyse du dataset via la méthode `df.isna().sum()` confirme l'absence totale de valeurs manquantes sur l'ensemble des 31 colonnes. Le dataset est donc complet et ne nécessite pas d'imputation.

3.3 Déséquilibre des classes

Le dataset est fortement déséquilibré, comme le montrent les effectifs ci-dessous :

Classe	Répartition
Classe 0 (Légitime)	284 315 transactions — 99,83 %
Classe 1 (Fraude)	492 transactions — 0,17 %

Ce déséquilibre extrême peut fausser l'évaluation des performances : une accuracy élevée peut masquer une très mauvaise détection de la fraude. Un modèle qui prédirait systématiquement « pas de fraude » obtiendrait une accuracy de 99,83 % sans détecter une seule fraude.

3.4 Gestion des outliers

L'analyse des boxplots révèle la présence d'outliers sur la quasi-totalité des variables (hors Time). La stratégie adoptée consiste à appliquer une transformation par racine cubique sur les variables numériques (hors Class et Time). Ce choix est motivé par plusieurs raisons :

- Le logarithme ne peut pas être utilisé en raison de la présence de valeurs nulles ou négatives.
- La suppression des lignes outliers est exclue, car leur nombre est trop élevé et entraînerait une perte majeure d'information.
- Le capping IQR risquerait d'influencer fortement la distribution des variables anonymisées.

La transformation racine cubique réduit significativement l'impact des outliers tout en préservant le signe des valeurs. Après transformation, les boxplots confirment une diminution considérable des outliers, bien que quelques valeurs extrêmes subsistent. Pour la variable « Amount » notamment, les grandes valeurs reflètent des transactions légitimes de clients professionnels ou d'entreprises, et non nécessairement des anomalies.

3.5 Stratégie face au déséquilibre

Trois approches ont été considérées et rejetées pour leur inadéquation dans ce contexte :

- SMOTE (oversampling) : risque fort de surapprentissage vu l'écart de classes.
- Undersampling : réduction trop importante de la classe majoritaire.
- Fusion de classes : impossible en classification binaire.

La stratégie retenue combine plusieurs mécanismes complémentaires :

- Pondération des classes (`class_weight='balanced'`) pour la Régression Logistique et Random Forest.
- Paramètre `scale_pos_weight` calculé pour XGBoost (valeur $\approx 577,9$).
- Évaluation prioritaire sur les métriques fraude (precision, recall, F1-score de la classe 1).
- Comparaison multi-modèles pour identifier le meilleur compromis.

3.6 Découpage et standardisation

Les données sont divisées en ensemble d'entraînement (70 %) et de test (30 %) avec stratification pour maintenir la proportion des classes. Une standardisation (Standard-Scaler) est appliquée pour la Régression Logistique et le Deep Learning, tandis que XGBoost et Random Forest sont utilisés sur les données non standardisées.

4. Étape 3 — Exploration des Données (EDA)

4.1 Distribution des classes

La visualisation de la distribution confirme un déséquilibre massif : la classe fraude représente moins de 0,2 % des transactions totales. Ce constat renforce la nécessité d'utiliser des métriques adaptées plutôt que l'accuracy globale.

4.2 Analyse du montant

Avant transformation, les statistiques descriptives de la variable Amount révèlent une distribution très asymétrique : moyenne de 88,35 €, médiane de 22 € et maximum atteignant 25 691,16 €. Cette asymétrie importante est cohérente avec des transactions bancaires réelles (petites transactions quotidiennes vs. grosses transactions professionnelles). Après transformation par racine cubique, la distribution est considérablement aplatie (moyenne $\approx 3,25$).

4.3 Corrélations

La matrice de corrélation montre des coefficients globalement faibles (entre 0 % et environ 10 %). Ce résultat est cohérent avec la nature des variables : les colonnes V1 à V28 étant des composantes principales issues d'une ACP, elles sont par construction décorréliées entre elles. Aucune collinéarité forte n'est détectée.

4.4 Variables influentes

L'analyse des importances de variables (calculée à partir du modèle XGBoost) identifie V14 comme la variable la plus influente dans la décision du modèle. Cela signifie que la composante principale V14 capture les patterns transactionnels les plus discriminants entre fraude et transaction légitime. En termes métier, la détection repose sur des combinaisons de signaux transactionnels (non directement interprétables nominativement en raison de l'anonymisation PCA), et non sur une simple règle univariée.

5. Étape 4 — Modélisation Machine Learning

5.1 Méthodologie

Trois algorithmes ont été testés et comparés, chacun bénéficiant d'un mécanisme de gestion du déséquilibre adapté à sa nature :

- **Régression Logistique** : Une recherche par grille (GridSearchCV, 5-fold cross-validation) a été réalisée sur les hyperparamètres suivants : régularisation (L1, L2, ElasticNet), pondération des classes et constante C. Les meilleurs paramètres identifiés sont : $C=100$, `class_weight='balanced'`, `penalty='l2'`.
- **Random Forest** : Un modèle à 1000 arbres avec `class_weight='balanced'` a été entraîné directement sur les données transformées (sans standardisation, les arbres n'en ayant pas besoin).
- **XGBoost** : Un modèle XGBoost à 1000 estimateurs a été entraîné avec un `scale_pos_weight` calculé comme le ratio entre classes : $284\,315 / 492 \approx 577,9$. Ce paramètre indique au modèle de pénaliser davantage les erreurs sur la classe minoritaire.

5.2 Résultats comparatifs

Modèle	Precision (Fraude)	Recall (Fraude)	F1-Score (Fraude)
Logistic Regression	0.05	0.87	0.09
Random Forest	0.97	0.70	0.82
XGBoost	0.93	0.76	0.84

5.3 Analyse des résultats

Régression Logistique : La régression logistique présente un recall très élevé (87 %), ce qui signifie qu'elle détecte la grande majorité des fraudes. Cependant, sa précision est extrêmement faible (5 %), générant un volume considérable de faux positifs : parmi toutes les transactions signalées comme frauduleuses, seulement 5 % le sont réellement. Un tel modèle entraînerait un blocage massif de clients innocents, inacceptable en production.

Random Forest : Le Random Forest marque une amélioration considérable avec une précision de 97 % et un F1-score de 82 %. La précision est quasi-parfaite, mais le recall de 70 % signifie que 30 % des fraudes passent inaperçues. C'est un meilleur compromis opérationnel, mais le taux de fraudes manquées reste élevé.

XGBoost : XGBoost offre le meilleur compromis global avec un F1-score de 84 %, une précision de 93 % et un recall de 76 %. Il détecte plus de fraudes que Random Forest tout en maintenant une précision élevée, réduisant ainsi les faux positifs à un niveau acceptable.

5.4 Surapprentissage (Overfitting)

L'analyse des courbes d'apprentissage (LearningCurveDisplay) sur XGBoost révèle un problème de surapprentissage : le score sur les données d'entraînement est significativement supérieur au score de validation. Ce phénomène impose vigilance sur la généralisation du modèle et justifie un monitoring post-déploiement, ainsi qu'une régularisation plus poussée.

5.5 Modèle recommandé

Au vu des résultats, XGBoost est recommandé comme modèle de production. Il conserve un recall satisfaisant (76 %) tout en garantissant une précision nettement supérieure à la régression logistique (93 %), offrant ainsi le meilleur équilibre entre détection des fraudes et expérience client préservée.

6. Étape 5 — Deep Learning

6.1 Architecture du réseau

Un réseau de neurones dense (Fully Connected Neural Network) a été construit avec l'architecture suivante : [cite : 112]

- Couche d'entrée : Dense(128, relu) + BatchNormalization + Dropout(0.5)
- Couche cachée 1 : Dense(64, relu) + BatchNormalization + Dropout(0.5)
- Couche cachée 2 : Dense(32, relu) + BatchNormalization + Dropout(0.5)
- Couche cachée 3 : Dense(16, relu) + BatchNormalization + Dropout(0.5)
- Couche de sortie : Dense(1, sigmoid) — activation adaptée à la classification binaire
-

Le modèle est compilé avec l'optimiseur Adam et la fonction de perte `binary_crossentropy`. Un `EarlyStopping` (`patience=10`, `monitor='val_loss'`, `restore_best_weights=True`) est utilisé pour interrompre l'entraînement dès que la perte de validation cesse de s'améliorer.

6.2 Résultats

- Precision (fraude) : 0.80
- Recall (fraude) : 0.78
- F1-Score (fraude) : 0.79
- Accuracy globale : 99.93 %

6.3 Comparaison avec les modèles ML classiques

Le Deep Learning offre des performances correctes mais ne dépasse pas XGBoost sur le compromis final fraude. En termes de F1-score (0.79 vs 0.84) et de précision (0.80 vs 0.93), XGBoost reste supérieur. Par ailleurs, le Deep Learning présente plusieurs désavantages dans ce contexte :

- Complexité d'entraînement significativement plus élevée (temps de calcul, réglage des hyperparamètres).
- Interprétation et explicabilité plus difficiles (boîte noire).
- Gain de performance non significatif par rapport à XGBoost.

Conclusion : le Deep Learning est utile comme benchmark de référence, mais dans ce cas précis, XGBoost reste le choix le plus judicieux pour un déploiement opérationnel.

7. Étape 6 — Explicabilité du Modèle

7.1 Importance des variables

L'explicabilité du modèle repose sur l'analyse des importances de variables calculées par XGBoost. La variable V14 se distingue comme la plus influente dans la prise de décision du modèle, suivie des autres composantes principales.

7.2 Interprétation

Une transaction est classée comme frauduleuse lorsque la combinaison des variables (dont V14 en première position) s'écarte significativement des patterns observés sur les transactions légitimes lors de l'entraînement. Le modèle est partiellement explicable : les importances de features sont disponibles et permettent d'identifier les signaux déterminants. Cependant, les variables étant des composantes principales anonymisées, leur traduction en termes métier reste limitée.

7.3 Niveau de confiance

La confiance dans le modèle doit être conditionnée à :

- Une validation régulière sur de nouvelles données (monitoring des performances).
- Un calibrage du seuil de décision en fonction du coût métier réel.
- Une revue humaine pour les cas à fort enjeu ou à score ambigu.
- L'intégration future de méthodes d'explicabilité locale (ex. SHAP) pour l'analyse de cas individuels.

Le compromis retenu est : performance + explicabilité opérationnelle (pas de boîte noire non gouvernée).

8. Étape 7 — Sécurité et Éthique

8.1 Risques identifiés

Blocage d'un client innocent (Faux Positif) Un faux positif entraîne le blocage injustifié d'une transaction légitime, impactant directement l'expérience client et la relation de confiance avec la banque. Mesure recommandée : mise en place d'une procédure rapide de vérification et de déblocage, avec notification proactive du client.

Risque de biais Le modèle peut être biaisé selon la représentativité des données d'entraînement ou leur dérive temporelle (concept drift). Les comportements frauduleux évoluent constamment. Mesures recommandées : audits périodiques du modèle, suivi des métriques d'équité opérationnelle et recalibrage régulier.

Vie privée et données sensibles : Les données transactionnelles sont hautement sensibles. La banque est soumise aux obligations de minimisation des données, de contrôle d'accès strict, de traçabilité des traitements et de sécurisation des modèles et pipelines.

Attaques adversariales : Le modèle est potentiellement vulnérable à des attaques adversariales : des fraudeurs pourraient apprendre à contourner le système de détection. Mesure recommandée : défense multicouche combinant règles métier, IA, détection d'anomalies et supervision humaine.

Justice de la décision automatique Aucun système automatisé n'est parfaitement juste. Le modèle doit rester un outil d'aide à la décision, avec un humain dans la boucle pour les cas critiques ou à fort impact financier.

8.2 Recommandations globales pour la Benin Bank

- Déployer XGBoost avec un seuil de décision calibré selon le coût métier réel (et non le seuil par défaut de 0.5).
- Conserver une revue humaine pour les transactions à fort score de risque.
- Monitorer en continu les métriques recall, precision et F1-score de la classe fraude.
- Recalibrer régulièrement le modèle pour compenser la dérive des données.
- Intégrer une gouvernance éthique et des protocoles de sécurité robustes.

9. Discussion et Limites

9.1 Points forts

- Pipeline complet et cohérent avec la problématique des classes rares.
- Comparaison solide de trois modèles ML + un modèle Deep Learning.
- Prise en compte explicite du compromis precision/recall.
- Gestion intelligente des outliers par transformation racine cubique.
- Analyse de surapprentissage par courbes d'apprentissage.

9.2 Limites

- Variables PCA anonymisées limitant l'interprétation métier fine.
- Déséquilibre extrême rendant l'évaluation sensible au choix des seuils.
- Surapprentissage détecté sur XGBoost (à encadrer en production).
- Absence de validation temporelle (split chronologique non réalisé).

9.3 Perspectives

- Calibration des seuils de décision en fonction du coût métier réel (analyse coût-bénéfice).
- Validation temporelle par split chronologique pour tester la robustesse dans le temps.
- Intégration de SHAP pour l'explicabilité locale et l'analyse de cas individuels.
- Déploiement pilote avec boucle de feedback des analystes fraude.
- Exploration de méthodes d'ensemble plus avancées (stacking, blending).

10. Conclusion et Recommandations

Ce projet démontre qu'une approche data science rigoureuse, orientée déséquilibre et métriques fraude, permet d'obtenir des résultats pertinents et exploitables dans un contexte bancaire réel. Parmi les quatre modèles testés, XGBoost offre le meilleur compromis opérationnel avec un F1-score de 84 %, une précision de 93 % et un recall de 76 % sur la classe fraude. La Régression Logistique détecte davantage de fraudes (recall 87 %) mais au prix d'un volume de faux positifs inacceptable en production (précision 5 %). Le Random Forest constitue un très bon modèle alternatif (F1 82 %, précision 97 %) mais avec

un recall légèrement inférieur. Le Deep Learning reste compétitif mais n'apporte pas d'avantage décisif ici. La recommandation finale est de déployer un système basé sur XGBoost avec une gouvernance robuste : calibrage des seuils selon le coût métier, surveillance continue des performances, mécanismes de revue humaine pour les cas critiques, et respect des exigences éthiques et de sécurité. Ce système représente un premier pas significatif vers une banque plus sûre, plus réactive et mieux armée face aux menaces de fraude croissantes, tout en préservant la qualité de service et la confiance de ses clients.